

Algoritmo de Machine Learning para el Pronóstico de Series Temporales con Distribución de Poisson Generalizada

Autor:

Artemio Araya Day

Fecha: 05-09-2026

1. Serie Temporal que distribuye Poisson Generalizada

Sea

$$Y_t$$

una variable aleatoria que representa el número de eventos observados durante el período t , con

$$t = 1, 2, \dots, T$$

Se supone que cada variable aleatoria Y_t sigue una distribución de Poisson generalizada con parámetros λ_t y ρ (Consul and Jain, 1973)

$$Y_t \sim \text{GP}(\lambda_t, \rho),$$

Distribución de Poisson Generalizada para Número de Eventos

$$P_{GP}(Y_t = x; \lambda_t, \rho) =$$

$$\lambda_t (\lambda_t + \rho x)^{x-1} \exp [-(\lambda_t + \rho x)] \frac{1}{x!}$$

$$, x = 0, 1, 2, \dots$$

1.1. Esperanza y Desviación Estándar de Distribución de Poisson Generalizada

Para todo $t = 1, \dots, T$ tenemos las siguientes características asociadas a la distribución de Poisson Generalizada (Consul and Jain, 1973).

Valor Esperado

$$\mathbb{E}[Y_t] = \frac{\lambda_t}{1-\rho}$$

$$\lambda_t \frac{\rho}{(1-\rho)^2}$$

Desviación Estándar

$$\sigma[Y_t] = \sqrt{\frac{\lambda_t}{(1-\rho)^3}}$$

$$\sqrt{\frac{\lambda_t}{(1-\rho)^3}}$$

1.2. Distribución de Poisson Generalizada expresada en función de μ_t y ρ

La distribución de poisson generalizada asociada a cada variable aleatoria Y_t depende de los parámetros λ_t y ρ para todo $t = 1, \dots, T$ (Consul and Jain, 1973).

Si definimos

$$\mu_t = \frac{\lambda_t}{1 - \rho}$$

$E[Y_t]$

$$\mu_t = \frac{\lambda_t}{1 - \rho}$$

Lo que implica

$$P_{GP}(Y_t = x \mid \mu_t, \rho) = \frac{\mu_t (1 - \rho) [\mu_t (1 - \rho) + \rho x]^{x-1}}{x! \exp[-\mu_t (1 - \rho) - \rho x]}$$

2. Verosimilitud de la muestra de la Distribución de Poisson Generalizada

Considérese una muestra de T observaciones

$$\mathbf{y} = \text{=====}$$

$$(y_1, y_2, \dots, y_T).$$

Supongamos estas variables aleatorias

$$Y_1, Y_2, \dots, Y_T$$

son independientes

La probabilidad conjunta de observar la muestra es el producto de las probabilidades individuales (Casella and Berger, 2002). Por lo tanto la Verosimilitud de la Muestra es

$$\mathcal{L} = \text{=====}$$

$$P_{GP}(Y_1 = y_1, Y_2 = y_2, \dots, Y_T = y_T).$$

Debido al supuesto de independencia,

$$\mathcal{L} = \text{=====}$$

$$\prod_{t=1}^T P_{GP}(Y_t = y_t; \lambda_t, \rho)$$

Utilizando la distribución de Poisson generalizada,

$$\mathcal{L} = \text{=====}$$

$$\prod_{t=1}^T \frac{\lambda_t (\lambda_t + \rho y_t)^{y_t - 1} \exp[-(\lambda_t + \rho y_t)]}{y_t!}$$

2.1. Parametrización del Valor Esperado con Modelo temporal

El valor esperado de la variable aleatoria no se considera constante, sino que se modela como una función del tiempo t .

Por lo tanto,

$$\mu_t =$$

$$\mu(t; \boldsymbol{\theta}),$$

La verosimilitud puede escribirse entonces como

$$\mathcal{L}(\boldsymbol{\theta}, \rho \mid \mathbf{y}) =$$

$$\prod_{t=1}^T \frac{\mu(t; \boldsymbol{\theta})^{y_t} (1 - \mu(t; \boldsymbol{\theta}))^{1 - y_t}}{y_t!} \exp[-\mu(t; \boldsymbol{\theta})]$$

2.2. Función Objetivo

Maximizar la verosimilitud equivale exactamente a minimizar la log-verosimilitud negativa (Casella and Berger, 2002)

$$\mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) = \sum_{t=1}^T \left[\mu_t(1 - \rho) + \rho y_t - \log(\mu_t(1 - \rho)) - (y_t - 1) \log(\mu_t(1 - \rho) + \rho y_t) + \log(y_t!) \right]$$

2.3. Modelo con Logística Generalizada

(Richards, 1959)

$$\mu(t; \theta) =$$

$$L + K - L \frac{1}{[1 + A \exp(-r(t - t_0))]^{1/\nu}}, (1)$$

donde

$$\theta =$$

$$(L, K, A, r, t_0, \nu). (2)$$

2.4. Modelo multiplicativo de tendencia de Logística Generalizada y estacionalidad con Series de Fourier

El Modelo Temporal representa el valor esperado de la distribución de poisson generalizada parametrizada en función del tiempo, posee una componente tendencial y una estacional multiperiodica formada por componentes sinusoidales con periodos independientes.

La estacionalidad se modela de forma multiplicativa ya que de este modo representa variaciones relativas o porcentuales respecto del nivel de la tendencia, en lugar de variaciones absolutas (Hyndman and Athanasopoulos, 2021).

$$\mu(t; \theta) =$$

$$g(t; \theta_1) \exp(s(t; \theta_2))$$

$g(t; \theta_1)$: Componente Tendencial.

$s(t; \theta_2)$: Componente Estacional.

2.4.1. Componente Tendencial con Logística Generalizada

(Richards, 1959)

$$g(t; \theta_1) =$$

$$L + K - L \frac{1}{[1 + A \exp(-r(t - t_0))]^{1/\nu}},$$

dónde

$$\theta_1 =$$

$$(L, K, A, r, t_0, \nu).$$

2.4.2. Componente Estacional mediante Componentes Sinusoidales con Períodos Independientes

La componente estacional se define como (Hyndman and Athanasopoulos, 2021; Taylor and Letham, 2018)

$$s(t; \theta_2) = \sum_{j=1}^3 \left[a_j \cos\left(\frac{2\pi t}{P_j}\right) + b_j \sin\left(\frac{2\pi t}{P_j}\right) \right].$$

Equivalentemente, la componente estacional puede escribirse de forma expandida como

$$s(t; \theta_2) = a_1 \cos\left(\frac{2\pi t}{P_1}\right) + b_1 \sin\left(\frac{2\pi t}{P_1}\right) + a_2 \cos\left(\frac{2\pi t}{P_2}\right) + b_2 \sin\left(\frac{2\pi t}{P_2}\right) + a_3 \cos\left(\frac{2\pi t}{P_3}\right) + b_3 \sin\left(\frac{2\pi t}{P_3}\right).$$

Los parámetros

$$a_1, b_1, a_2, b_2, a_3, b_3$$

determinan la amplitud y la fase de cada componente sinusoidal, mientras que los parámetros

$$P_1, P_2, P_3$$

determinan sus respectivos períodos.

Por lo tanto, el vector de parámetros asociado a la componente estacional se define como

$$\theta_2 = (a_1, b_1, P_1, a_2, b_2, P_2, a_3, b_3, P_3).$$

Cada componente sinusoidal permite representar una periodicidad distinta dentro de la serie temporal.

2.4.3. Problema

Modelo Temporal de Número de Eventos Promedio

$$\mu(t) = \left[L + \frac{K - L}{(1 + Ae^{-r(t-t_0)})^{1/\nu}} \right] \cdot \exp \left[\begin{array}{l} a_1 \cos \left(\frac{2\pi t}{P_1} \right) + b_1 \sin \left(\frac{2\pi t}{P_1} \right) \\ + a_2 \cos \left(\frac{2\pi t}{P_2} \right) + b_2 \sin \left(\frac{2\pi t}{P_2} \right) \\ + a_3 \cos \left(\frac{2\pi t}{P_3} \right) + b_3 \sin \left(\frac{2\pi t}{P_3} \right) \end{array} \right]$$

3. Problema de Optimización con Regularización Ridge

El objetivo del algoritmo consiste en estimar los parámetros del modelo temporal y de la distribución de Poisson Generalizada mediante el método de máxima verosimilitud.

Maximizar la verosimilitud de la muestra es equivalente a minimizar la log-verosimilitud negativa. Por lo tanto, se define la función de pérdida

$$\mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) = -\log(\mathcal{L}(\boldsymbol{\theta}, \rho \mid \mathbf{y})).$$

Utilizando la parametrización de la distribución de Poisson Generalizada, la función de log-verosimilitud negativa queda dada por

$$\mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) = \sum_{t=1}^T \left[\mu(t; \boldsymbol{\theta})(1 - \rho) + \rho y_t - \log(\mu(t; \boldsymbol{\theta})(1 - \rho)) - (y_t - 1) \log(\mu(t; \boldsymbol{\theta})(1 - \rho) + \rho y_t) + \log(y_t!) \right]$$

Para reducir el riesgo de sobreajuste se incorpora una regularización Ridge, que corresponde a una penalización cuadrática sobre los parámetros (Hoerl and Kennard, 1970).

La penalización Ridge se define como

$$\mathcal{J}_{\text{Ridge}}(\boldsymbol{\theta}) = \lambda_R \left(\sum_{k=1}^p \theta_k^2 \right)$$

y $\lambda_R \geq 0$ representa el parámetro que controla la intensidad de la regularización. Por lo tanto, la función objetivo total del algoritmo queda definida como

$$\mathcal{J}(\boldsymbol{\theta}, \rho) = \mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) + \mathcal{J}_{\text{Ridge}}(\boldsymbol{\theta})$$

El problema de optimización puede expresarse entonces como

$$(\boldsymbol{\theta}^*, \rho^*) = \arg \min_{\boldsymbol{\theta}, \rho} \mathcal{J}(\boldsymbol{\theta}, \rho)$$

Bibliografía

Referencias

- Casella, G. y Berger, R. L. (2002). *Statistical Inference* (2nd ed.). Duxbury, Pacific Grove, California.
- Consul, P. C. y Jain, G. C. (1973). A Generalization of the Poisson Distribution. *Technometrics*, 15(4), 791-799. doi:10.1080/00401706.1973.10489112.
- Hoerl, A. E. y Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55-67. doi:10.1080/00401706.1970.10488634.
- Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3rd ed.). OTexts, Melbourne, Australia.
- Richards, F. J. (1959). A Flexible Growth Function for Empirical Use. *Journal of Experimental Botany*, 10(2), 290-301. doi:10.1093/jxb/10.2.290.
- Taylor, S. J. y Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37-45. doi:10.1080/00031305.2017.1380080.