

Algoritmo de Machine Learning para el Pronóstico de Series Temporales con Distribución de Poisson Generalizada

Autor:

Artemio Araya Day

Fecha: 05-09-2026

1. Serie Temporal que distribuye Poisson Generalizada

Sea

$$Y_t$$

una variable aleatoria que representa el número de eventos observados durante el período t , con

$$t = 1, 2, \dots, T.$$

Se supone que cada variable aleatoria Y_t sigue una distribución de Poisson Generalizada con parámetros λ_t y ρ (Consul and Jain, 1973).

$$Y_t \sim \text{GP}(\lambda_t, \rho).$$

Distribución de Poisson Generalizada para Número de Eventos:

$$P_{GP}(Y_t = x; \lambda_t, \rho) = \frac{\lambda_t (\lambda_t + \rho x)^{x-1}}{x!} \exp [- (\lambda_t + \rho x)],$$

$$x = 0, 1, 2, \dots$$

1.1. Esperanza y Desviación Estándar de Distribución de Poisson Generalizada

Para todo $t = 1, \dots, T$ tenemos las siguientes características asociadas a la distribución de Poisson Generalizada (Consul and Jain, 1973).

Valor Esperado

$$\mathbb{E}[Y_t] = \frac{\lambda_t}{1 - \rho}$$

Desviación Estándar

$$\sigma[Y_t] = \sqrt{\frac{\lambda_t}{(1 - \rho)^3}}$$

1.2. Distribución de Poisson Generalizada expresada en función de μ_t y ρ

La distribución de Poisson Generalizada asociada a cada variable aleatoria Y_t depende de los parámetros λ_t y ρ para todo $t = 1, \dots, T$ (Consul and Jain, 1973).

Si definimos

$$\mu_t = \mathbb{E}[Y_t]$$

entonces

$$\mu_t = \frac{\lambda_t}{1 - \rho}.$$

Por lo tanto,

$$\lambda_t = \mu_t(1 - \rho).$$

Lo que implica

$$P_{GP}(Y_t = x \mid \mu_t, \rho) = \frac{\mu_t(1 - \rho) [\mu_t(1 - \rho) + \rho x]^{x-1}}{x!} \exp [-\mu_t(1 - \rho) - \rho x].$$

2. Verosimilitud de la muestra de la Distribución de Poisson Generalizada

Considérese una muestra de T observaciones

$$\mathbf{y} = (y_1, y_2, \dots, y_T).$$

Supongamos que las variables aleatorias

$$Y_1, Y_2, \dots, Y_T$$

son independientes.

La probabilidad conjunta de observar la muestra es el producto de las probabilidades individuales (Casella and Berger, 2002). Por lo tanto, la verosimilitud de la muestra es

$$\mathcal{L} = P_{GP}(Y_1 = y_1, Y_2 = y_2, \dots, Y_T = y_T).$$

Debido al supuesto de independencia,

$$\mathcal{L} = \prod_{t=1}^T P_{GP}(Y_t = y_t; \lambda_t, \rho).$$

Utilizando la distribución de Poisson Generalizada,

$$\mathcal{L} = \prod_{t=1}^T \frac{\lambda_t (\lambda_t + \rho y_t)^{y_t-1}}{y_t!} \exp[-(\lambda_t + \rho y_t)].$$

2.1. Parametrización del Valor Esperado con Modelo Temporal

El valor esperado de la variable aleatoria no se considera constante, sino que se modela como una función del tiempo t .

Por lo tanto,

$$\mu_t = \mu(t; \boldsymbol{\theta}).$$

La verosimilitud puede escribirse entonces como

$$\mathcal{L}(\boldsymbol{\theta}, \rho \mid \mathbf{y}) = \prod_{t=1}^T \frac{\mu(t; \boldsymbol{\theta})(1 - \rho) [\mu(t; \boldsymbol{\theta})(1 - \rho) + \rho y_t]^{y_t - 1}}{y_t!} \exp [-\mu(t; \boldsymbol{\theta})(1 - \rho) - \rho y_t].$$

2.2. Función Objetivo

Maximizar la verosimilitud equivale exactamente a minimizar la log-verosimilitud negativa (Casella and Berger, 2002).

$$\mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) = \sum_{t=1}^T \left[\mu_t(1 - \rho) + \rho y_t - \log(\mu_t(1 - \rho)) - (y_t - 1) \log(\mu_t(1 - \rho) + \rho y_t) + \log(y_t!) \right]$$

2.3. Modelo con Logística Generalizada

La logística generalizada utilizada corresponde a la familia propuesta por Richards (1959).

$$\mu(t; \boldsymbol{\theta}) = L + \frac{K - L}{[1 + A \exp(-r(t - t_0))]^{1/\nu}}. \quad (1)$$

donde

$$\boldsymbol{\theta} = (L, K, A, r, t_0, \nu). \quad (2)$$

2.4. Modelo multiplicativo de tendencia de Logística Generalizada y estacionalidad con Series de Fourier

El Modelo Temporal representa el valor esperado de la distribución de Poisson Generalizada parametrizada en función del tiempo. Posee una componente tendencial y una componente estacional multiperiódica formada por componentes sinusoidales con períodos independientes.

La estacionalidad se modela de forma multiplicativa, ya que de este modo representa variaciones relativas o porcentuales respecto del nivel de la tendencia, en lugar de variaciones absolutas (Hyndman and Athanasopoulos, 2021).

$$\mu(t; \boldsymbol{\theta}) = g(t; \boldsymbol{\theta}_1) \exp(s(t; \boldsymbol{\theta}_2)).$$

$g(t; \boldsymbol{\theta}_1)$: Componente Tendencial.

$s(t; \boldsymbol{\theta}_2)$: Componente Estacional.

2.4.1. Componente Tendencial con Logística Generalizada

La componente tendencial se modela utilizando la función logística generalizada de Richards (Richards, 1959).

$$g(t; \boldsymbol{\theta}_1) = L + \frac{K - L}{[1 + A \exp(-r(t - t_0))]^{1/\nu}}.$$

donde

$$\boldsymbol{\theta}_1 = (L, K, A, r, t_0, \nu).$$

2.4.2. Componente Estacional mediante Componentes Sinusoidales con Períodos Independientes

La componente estacional se define mediante una combinación de términos sinusoidales, siguiendo el uso habitual de términos de Fourier en modelos de series temporales (Hyndman and Athanasopoulos, 2021; Taylor and Letham, 2018).

$$s(t; \theta_2) = \sum_{j=1}^3 \left[a_j \cos \left(\frac{2\pi t}{P_j} \right) + b_j \sin \left(\frac{2\pi t}{P_j} \right) \right].$$

Equivalentemente, la componente estacional puede escribirse de forma expandida como

$$\begin{aligned} s(t; \theta_2) = & a_1 \cos \left(\frac{2\pi t}{P_1} \right) + b_1 \sin \left(\frac{2\pi t}{P_1} \right) \\ & + a_2 \cos \left(\frac{2\pi t}{P_2} \right) + b_2 \sin \left(\frac{2\pi t}{P_2} \right) \\ & + a_3 \cos \left(\frac{2\pi t}{P_3} \right) + b_3 \sin \left(\frac{2\pi t}{P_3} \right). \end{aligned}$$

Los parámetros

$$a_1, b_1, a_2, b_2, a_3, b_3$$

determinan la amplitud y la fase de cada componente sinusoidal, mientras que los parámetros

$$P_1, P_2, P_3$$

determinan sus respectivos períodos.

Por lo tanto, el vector de parámetros asociado a la componente estacional se define como

$$\theta_2 = (a_1, b_1, P_1, a_2, b_2, P_2, a_3, b_3, P_3).$$

Cada componente sinusoidal permite representar una periodicidad distinta dentro de la serie temporal.

2.4.3. Problema

Modelo Temporal de Número de Eventos Promedio

$$\mu(t) = \left[L + \frac{K - L}{(1 + Ae^{-r(t-t_0)})^{1/\nu}} \right] \cdot \exp \left[\begin{array}{l} a_1 \cos \left(\frac{2\pi t}{P_1} \right) + b_1 \sin \left(\frac{2\pi t}{P_1} \right) \\ + a_2 \cos \left(\frac{2\pi t}{P_2} \right) + b_2 \sin \left(\frac{2\pi t}{P_2} \right) \\ + a_3 \cos \left(\frac{2\pi t}{P_3} \right) + b_3 \sin \left(\frac{2\pi t}{P_3} \right) \end{array} \right]$$

3. Problema de Optimización con Regularización Ridge

El objetivo del algoritmo consiste en estimar los parámetros del modelo temporal y de la distribución de Poisson Generalizada mediante el método de máxima verosimilitud.

Maximizar la verosimilitud de la muestra es equivalente a minimizar la log-verosimilitud negativa. Por lo tanto, se define la función de pérdida

$$\mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) = -\log(\mathcal{L}(\boldsymbol{\theta}, \rho \mid \mathbf{y})).$$

Utilizando la parametrización de la distribución de Poisson Generalizada, la función de log-verosimilitud negativa queda dada por

$$\mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) = \sum_{t=1}^T \left[\mu(t; \boldsymbol{\theta})(1 - \rho) + \rho y_t - \log(\mu(t; \boldsymbol{\theta})(1 - \rho)) \right. \\ \left. - (y_t - 1) \log(\mu(t; \boldsymbol{\theta})(1 - \rho) + \rho y_t) + \log(y_t!) \right].$$

Para reducir el riesgo de sobreajuste se incorpora una regularización Ridge, que corresponde a una penalización cuadrática sobre los parámetros (Hoerl and Kennard, 1970).

La penalización Ridge se define como

$$\mathcal{J}_{\text{Ridge}}(\boldsymbol{\theta}) = \lambda_{\text{R}} \left(\sum_{k=1}^p \theta_k^2 \right).$$

donde $\lambda_{\text{R}} \geq 0$ representa el parámetro que controla la intensidad de la regularización.

Por lo tanto, la función objetivo total del algoritmo queda definida como

$$\mathcal{J}(\boldsymbol{\theta}, \rho) = \mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) + \mathcal{J}_{\text{Ridge}}(\boldsymbol{\theta}).$$

El problema de optimización puede expresarse entonces como

$$(\boldsymbol{\theta}^*, \rho^*) = \arg \min_{\boldsymbol{\theta}, \rho} \mathcal{J}(\boldsymbol{\theta}, \rho).$$

Bibliografía

Referencias

- Casella, G. y Berger, R. L. (2002). *Statistical Inference*. 2nd ed. Duxbury, Pacific Grove, California.
- Consul, P. C. y Jain, G. C. (1973). A Generalization of the Poisson Distribution. *Technometrics*, 15(4), 791-799. doi:10.1080/00401706.1973.10489112.
- Hoerl, A. E. y Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55-67. doi:10.1080/00401706.1970.10488634.
- Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*. 3rd ed. OTexts, Melbourne, Australia.
- Richards, F. J. (1959). A Flexible Growth Function for Empirical Use. *Journal of Experimental Botany*, 10(2), 290-301. doi:10.1093/jxb/10.2.290.
- Taylor, S. J. y Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37-45. doi:10.1080/00031305.2017.1380080.