



**AUTO**MIND

# Algoritmo de Machine Learning para el Pronóstico de Series Temporales con Distribución de Poisson Generalizada

**Autor:** Artemio Araya Day

**Fecha:** 05-09-2026

# 1. Serie Temporal que distribuye Poisson Generalizada

Sea

$$Y_t$$

una variable aleatoria que representa el número de eventos observados durante el período  $t$ , con

$$t = 1, 2, \dots, T$$

Se supone que cada variable aleatoria  $Y_t$  sigue una distribución de Poisson Generalizada con parámetros  $\lambda_t$  y  $\rho$  (Consul and Jain, 1973).

$$Y_t \sim \text{GP}(\lambda_t, \rho)$$

Distribución de Poisson Generalizada para Número de Eventos:

$$P_{GP}(Y_t = x; \lambda_t, \rho) = \frac{\lambda_t (\lambda_t + \rho x)^{x-1}}{x!} \exp [ - (\lambda_t + \rho x) ],$$

$$x = 0, 1, 2, \dots$$

### 1.1. Esperanza y Desviación Estándar de Distribución de Poisson Generalizada

Para todo  $t = 1, \dots, T$  tenemos las siguientes características asociadas a la distribución de Poisson Generalizada (Consul and Jain, 1973).

Valor Esperado

$$\mathbb{E}[Y_t] = \frac{\lambda_t}{1 - \rho}$$

Desviación Estándar

$$\sigma[Y_t] = \sqrt{\frac{\lambda_t}{(1 - \rho)^3}}$$

## 1.2. Distribución de Poisson Generalizada expresada en función de $\mu_t$ y $\rho$

La distribución de Poisson Generalizada asociada a cada variable aleatoria  $Y_t$  depende de los parámetros  $\lambda_t$  y  $\rho$  para todo  $t = 1, \dots, T$  (Consul and Jain, 1973).

Si definimos

$$\mu_t = \mathbb{E}[Y_t]$$

entonces

$$\mu_t = \frac{\lambda_t}{1 - \rho}$$

Por lo tanto,

$$\lambda_t = \mu_t(1 - \rho)$$

Lo que implica

$$P_{GP}(Y_t = x \mid \mu_t, \rho) = \frac{\mu_t(1 - \rho) [\mu_t(1 - \rho) + \rho x]^{x-1}}{x!} \exp[-\mu_t(1 - \rho) - \rho x]$$

## 2. Verosimilitud de la muestra de la Distribución de Poisson Generalizada

Considérese una muestra de  $T$  observaciones

$$\mathbf{y} = (y_1, y_2, \dots, y_T)$$

Supongamos que las variables aleatorias

$$Y_1, Y_2, \dots, Y_T$$

son independientes.

La probabilidad conjunta de observar la muestra es el producto de las probabilidades individuales. Por lo tanto, la verosimilitud de la muestra es

$$\mathcal{L} = P_{GP}(Y_1 = y_1, Y_2 = y_2, \dots, Y_T = y_T)$$

Debido al supuesto de independencia,

$$\mathcal{L} = \prod_{t=1}^T P_{GP}(Y_t = y_t; \lambda_t, \rho)$$

Utilizando la distribución de Poisson Generalizada,

$$\mathcal{L} = \prod_{t=1}^T \frac{\lambda_t (\lambda_t + \rho y_t)^{y_t-1}}{y_t!} \exp [-(\lambda_t + \rho y_t)]$$

## 2.1. Parametrización del Valor Esperado con Modelo Temporal

El valor esperado de la variable aleatoria no se considera constante, sino que se modela como una función del tiempo  $t$ .

Por lo tanto,

$$\mu_t = \mu(t; \boldsymbol{\theta})$$

La verosimilitud puede escribirse entonces como

$$\mathcal{L}(\boldsymbol{\theta}, \rho \mid \mathbf{y}) = \prod_{t=1}^T \frac{\mu(t; \boldsymbol{\theta})(1 - \rho) [\mu(t; \boldsymbol{\theta})(1 - \rho) + \rho y_t]^{y_t - 1}}{y_t!} \exp [-\mu(t; \boldsymbol{\theta})(1 - \rho) - \rho y_t]$$

## 2.2. Función Objetivo

Maximizar la verosimilitud equivale exactamente a minimizar la log-verosimilitud negativa.

$$\mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) = \sum_{t=1}^T \left[ \mu_t(1 - \rho) + \rho y_t - \log(\mu_t(1 - \rho)) - (y_t - 1) \log(\mu_t(1 - \rho) + \rho y_t) + \log(y_t!) \right]$$

## 2.3. Modelo multiplicativo de tendencia de Logística Generalizada y estacionalidad con Series de Fourier

El Modelo Temporal representa el valor esperado de la distribución de Poisson Generalizada parametrizada en función del tiempo  $t$ .

Posee una componente tendencial convergente en el largo plazo y una estacional multiperiodica formada por componentes sinusoidales con periodos independientes.

La estacionalidad se modela de forma multiplicativa, ya que de este modo representa variaciones relativas o porcentuales respecto del nivel de la tendencia, en lugar de variaciones absolutas (Winters, 1960).

$$\mu(t; \boldsymbol{\theta}) = g(t; \boldsymbol{\theta}_1) \exp(s(t; \boldsymbol{\theta}_2))$$

$g(t; \boldsymbol{\theta}_1)$ : Componente Tendencial.

$s(t; \boldsymbol{\theta}_2)$ : Componente Estacional.

### 2.3.1. Componente Tendencial con Logística Generalizada

La componente tendencial se modela utilizando la función logística generalizada de Richards (Richards, 1959).

$$g(t; \boldsymbol{\theta}_1) = L + \frac{K - L}{[1 + A \exp(-z(t))]^{1/\nu}}$$

$z(t)$  puede representarse mediante la expansión de Taylor de una función analítica alrededor de  $t = 0$  (Taylor, 1715)

$$z(t) = \sum_{k=0}^{+\infty} \frac{z^{(k)}(0)}{k!} t^k$$

La selección de un polinomio de segundo orden permite que la velocidad de evolución temporal cambie gradualmente, incorporando aceleración o desaceleración mediante el coeficiente cuadrático  $\theta_2$ .

$$z(t) \approx \theta_0 + \theta_1 t + \theta_2 t^2$$

y el vector de parámetros de la componente tendencial es

$$\boldsymbol{\theta}_1 = (L, K, A, \nu, \theta_0, \theta_1, \theta_2).$$

### 2.3.2. Componente Estacional mediante Componentes Sinusoidales con Períodos Independientes

La componente estacional se define mediante una combinación de términos sinusoidales basada en la representación mediante series de Fourier (Fourier, 1822).

$$s(t; \theta_2) = \sum_{j=1}^n \left[ a_j \cos \left( \frac{2\pi t}{P_j} \right) + b_j \sin \left( \frac{2\pi t}{P_j} \right) \right]$$

Los parámetros

$$a_j, b_j, \quad j = 1, \dots, n$$

determinan la amplitud y la fase de cada componente sinusoidal, mientras que los parámetros fijos

$$P_j, \quad j = 1, \dots, n$$

determinan sus respectivos períodos.

Por lo tanto, el vector de parámetros asociado a la componente estacional se define como

$$\theta_2 = (a_1, b_1, a_2, b_2, \dots, a_n, b_n)$$

donde, para cada  $j = 1, \dots, n$ , el par de parámetros  $(a_j, b_j)$  corresponde a los coeficientes de las componentes coseno y seno asociadas al período  $P_j$ , respectivamente.

Cada componente sinusoidal permite representar una periodicidad distinta dentro de la serie temporal.

### 2.3.3. Formulación Final del Modelo Temporal

Por lo tanto, el Modelo Temporal es

$$\mu(t) = \left[ L + \frac{K - L}{(1 + Ae^{-(\theta_0 + \theta_1 t + \theta_2 t^2)})^{1/\nu}} \right] \cdot \exp \begin{bmatrix} a_1 \cos\left(\frac{2\pi t}{P_1}\right) + b_1 \sin\left(\frac{2\pi t}{P_1}\right) \\ + a_2 \cos\left(\frac{2\pi t}{P_2}\right) + b_2 \sin\left(\frac{2\pi t}{P_2}\right) \\ \dots \\ + a_n \cos\left(\frac{2\pi t}{P_n}\right) + b_n \sin\left(\frac{2\pi t}{P_n}\right) \end{bmatrix}.$$

### 3. Problema de Optimización con Regularización Ridge

El objetivo del algoritmo consiste en estimar los parámetros del modelo temporal y de la distribución de Poisson Generalizada mediante el método de máxima verosimilitud, desarrollado sistemáticamente por Fisher (Fisher, 1922).

Maximizar la verosimilitud de la muestra es equivalente a minimizar la log-verosimilitud negativa. Por lo tanto, se define la función de pérdida

$$\mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) = -\log(\mathcal{L}(\boldsymbol{\theta}, \rho \mid \mathbf{y}))$$

Utilizando la parametrización de la distribución de Poisson Generalizada, la función de log-verosimilitud negativa queda dada por

$$\mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) = \sum_{t=1}^T \left[ \mu(t; \boldsymbol{\theta})(1 - \rho) + \rho y_t - \log(\mu(t; \boldsymbol{\theta})(1 - \rho)) \right. \\ \left. - (y_t - 1) \log(\mu(t; \boldsymbol{\theta})(1 - \rho) + \rho y_t) + \log(y_t!) \right]$$

Para reducir el riesgo de sobreajuste se incorpora una regularización Ridge, que corresponde a una penalización cuadrática sobre los parámetros (Hoerl and Kennard, 1970).

La penalización Ridge se define como

$$\mathcal{J}_{\text{Ridge}}(\boldsymbol{\theta}) = \lambda_{\text{R}} \left( \sum_{k=1}^p \theta_k^2 \right)$$

donde  $\lambda_{\text{R}} \geq 0$  representa el parámetro que controla la intensidad de la regularización.

Por lo tanto, la función objetivo total del algoritmo queda definida como

$$\mathcal{J}(\boldsymbol{\theta}, \rho) = \mathcal{J}_{\text{NLL}}(\boldsymbol{\theta}, \rho) + \mathcal{J}_{\text{Ridge}}(\boldsymbol{\theta})$$

El problema de optimización puede expresarse entonces como

$$(\boldsymbol{\theta}^*, \rho^*) = \arg \min_{\boldsymbol{\theta}, \rho} \mathcal{J}(\boldsymbol{\theta}, \rho)$$

## Bibliografía

### Referencias

Taylor, B. (1715). *Methodus Incrementorum Directa et Inversa*. William Innys, London, England.

Fourier, J. B. J. (1822). *Théorie analytique de la chaleur*. Firmin Didot, Paris, France.

Fisher, R. A. (1922). On the Mathematical Foundations of Theoretical Statistics. *Philosophical Transactions of the Royal Society of London. Series A*, 222, 309-368. <https://doi.org/10.1098/rsta.1922.0009>  
doi:10.1098/rsta.1922.0009.

Richards, F. J. (1959). A Flexible Growth Function for Empirical Use. *Journal of Experimental Botany*, 10(2), 290-301.  
doi:10.1093/jxb/10.2.290.

Winters, P. R. (1960). Forecasting Sales by Exponentially Weighted Moving Averages. *Management Science*, 6(3), 324-342. doi:10.1287/mnsc.6.3.324.

Hoerl, A. E. y Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55-67.  
doi:10.1080/00401706.1970.10488634.

Consul, P. C. y Jain, G. C. (1973). A Generalization of the Poisson Distribution. *Technometrics*, 15(4), 791-799.  
doi:10.1080/00401706.1973.10489112.