

AUTOMIND

# Algoritmo de Machine Learning para el Pronóstico de Series Temporales con Distribución de Poisson Generalizada

**Autor:** Artemio Araya Day

**Fecha:** 05-09-2026

# 1. Serie Temporal que distribuye Poisson Generalizada

Sea

$$Y_t$$

una variable aleatoria que representa el número de eventos observados durante el período $t$, con

$$t = 1, 2, \ldots, T$$

Se supone que cada variable aleatoria $Y_t$ sigue una distribución de Poisson Generalizada con parámetros $\lambda_t$ y $\rho$ (Consul and Jain, 1973).

$$Y_t \sim \mathrm{GP}(\lambda_t, \rho)$$

Distribución de Poisson Generalizada para Número de Eventos:

$$P_{GP}(Y_t = x; \lambda_t, \rho) = \frac{\lambda_t \left(\lambda_t + \rho x\right)^{x-1}}{x!} \exp\left[-\left(\lambda_t + \rho x\right)\right],$$

$$x = 0, 1, 2, \ldots$$

## 1.1. Esperanza y Desviación Estándar de Distribución de Poisson Generalizada

Para todo $t = 1, \ldots, T$ tenemos las siguientes características asociadas a la distribución de Poisson Generalizada (Consul and Jain, 1973).

Valor Esperado

$$\mathbb{E}[Y_t] = \frac{\lambda_t}{1-\rho}$$

Desviación Estándar

$$\sigma[Y_t] = \sqrt{\frac{\lambda_t}{(1-\rho)^3}}$$

## 1.2. Distribución de Poisson Generalizada expresada en función de $\mu_t$ y $\rho$

La distribución de Poisson Generalizada asociada a cada variable aleatoria $Y_t$ depende de los parámetros $\lambda_t$ y $\rho$ para todo $t = 1, \ldots, T$ (Consul and Jain, 1973).

Si definimos

$$\mu_t = \mathbb{E}[Y_t]$$

entonces

$$\mu_t = \frac{\lambda_t}{1-\rho}$$

Por lo tanto,

$$\lambda_t = \mu_t(1-\rho)$$

Lo que implica

$$P_{GP}(Y_t = x \mid \mu_t, \rho) = \frac{\mu_t(1-\rho)\left[\mu_t(1-\rho)+\rho x\right]^{x-1}}{x!} \exp\left[-\mu_t(1-\rho)-\rho x\right]$$

## 2. Verosimilitud de la muestra de la Distribución de Poisson Generalizada

Considérese una muestra de $T$ observaciones

$$\boldsymbol{y} = (y_1, y_2, \ldots, y_T)$$

Supongamos que las variables aleatorias

$$Y_1, Y_2, \ldots, Y_T$$

son independientes.

La probabilidad conjunta de observar la muestra es el producto de las probabilidades individuales. Por lo tanto,
la verosimilitud de la muestra es

$$\mathcal{L} = P_{GP}\left(Y_1 = y_1, Y_2 = y_2, \ldots, Y_T = y_T\right)$$

Debido al supuesto de independencia,

$$\mathcal{L} = \prod_{t=1}^{T} P_{GP}(Y_t = y_t; \lambda_t, \rho)$$

Utilizando la distribución de Poisson Generalizada,

$$\mathcal{L} = \prod_{t=1}^{T} \frac{\lambda_t \left(\lambda_t + \rho y_t\right)^{y_t - 1}}{y_t!} \exp\left[-\left(\lambda_t + \rho y_t\right)\right]$$

## 2.1. Parametrización del Valor Esperado con Modelo Temporal

El valor esperado de la variable aleatoria no se considera constante, sino que se modela como una función del tiempo $t$.

Por lo tanto,

$$\mu_t = \mu(t; \boldsymbol{\theta})$$

La verosimilitud puede escribirse entonces como

$$\mathcal{L}(\boldsymbol{\theta}, \rho \mid \boldsymbol{y}) = \prod_{t=1}^{T} \frac{\mu(t;\boldsymbol{\theta})(1-\rho)\left[\mu(t;\boldsymbol{\theta})(1-\rho) + \rho y_t\right]^{y_t - 1}}{y_t!} \exp\left[-\mu(t;\boldsymbol{\theta})(1-\rho) - \rho y_t\right]$$

## 2.2. Función Objetivo

Maximizar la verosimilitud equivale exactamente a minimizar la log-verosimilitud negativa.

$$\mathcal{J}_{\mathrm{NLL}}(\boldsymbol{\theta}, \rho) = \sum_{t=1}^{T} \left[ \mu_t(1-\rho) + \rho y_t - \log\left(\mu_t(1-\rho)\right) - (y_t - 1)\log\left(\mu_t(1-\rho) + \rho y_t\right) + \log(y_t!) \right]$$

## 2.3. Modelo multiplicativo de tendencia de Logística Generalizada y estacionalidad con Series de Fourier

El Modelo Temporal representa el valor esperado de la distribución de Poisson Generalizada parametrizada en función del tiempo $t$.

Posee una componente tendencial convergente en el largo plazo y una estacional multiperiódica formada por componentes sinusoidales con períodos independientes.

La estacionalidad se incorpora de forma multiplicativa mediante una función exponencial, de modo que sus efectos representan variaciones relativas respecto del nivel de la tendencia, en lugar de variaciones absolutas. Esta formulación se fundamenta en el enfoque de estacionalidad multiplicativa descrito por (Winters, 1960).

Además, dado que la función exponencial es estrictamente positiva, esta transformación garantiza que el factor estacional sea siempre positivo y, en consecuencia, que el valor esperado del modelo también lo sea, siempre que la función de tendencia sea positiva.

$$\mu(t;\boldsymbol{\theta}) = g(t;\boldsymbol{\theta}_1)\exp\left(s(t;\boldsymbol{\theta}_2)\right)$$

$g(t;\boldsymbol{\theta}_1)$: Componente Tendencial.

$s(t;\boldsymbol{\theta}_2)$: Componente Estacional.

### 2.3.1. Componente Tendencial con Logística Generalizada

La componente tendencial se modela utilizando la función logística generalizada de Richards (Richards, 1959).

$$g(t;\boldsymbol{\theta}_1) = L + \frac{K-L}{\left[1 + A\exp\left(-z(t)\right)\right]^{1/\nu}}$$

$z(t)$ puede representarse mediante la expansión de Taylor de una función analítica alrededor de $t = 0$ (Taylor, 1715)

$$z(t) = \sum_{k=0}^{+\infty} \frac{z^{(k)}(0)}{k!}\, t^k$$

La selección de un polinomio de segundo orden permite que la velocidad de evolución temporal cambie gradualmente, incorporando aceleración o desaceleración mediante el coeficiente cuadrático $\theta_2$.

$$z(t) \approx \theta_0 + \theta_1 t + \theta_2 t^2$$

y el vector de parámetros de la componente tendencial es

$$\boldsymbol{\theta}_1 = (L, K, A, \nu, \theta_0, \theta_1, \theta_2)\,.$$

### 2.3.2. Componente Estacional mediante Componentes Sinusoidales con Períodos Independientes

La componente estacional se define mediante una combinación de términos sinusoidales basada en la representación mediante series de Fourier (Fourier, 1822).

Esta formulación está inspirada en el modelo *Prophet*, desarrollado originalmente por Facebook (actualmente Meta), que utiliza series de Fourier para representar la estacionalidad de las series temporales (Taylor y Letham, 2018).

A diferencia de Prophet, que emplea frecuencias armónicamente relacionadas dentro de cada componente estacional, el presente modelo permite especificar períodos fijos e independientes para cada componente sinusoidal.

$$s(t;\boldsymbol{\theta}_2) = \sum_{j=1}^{n} \left[ a_j \cos\left(\frac{2\pi t}{P_j}\right) + b_j \sin\left(\frac{2\pi t}{P_j}\right) \right]$$

Los parámetros

$$a_j, b_j, \quad j = 1, ..., n$$

determinan la amplitud y la fase de cada componente sinusoidal, mientras que los parámetros fijos

$$P_j, \quad j = 1, ..., n$$

determinan sus respectivos períodos.

Por lo tanto, el vector de parámetros asociado a la componente estacional se define como

$$\boldsymbol{\theta}_2 = (a_1, b_1, a_2, b_2, \ldots, a_n, b_n)$$

donde, para cada $j = 1, \ldots, n$, el par de parámetros $(a_j, b_j)$ corresponde a los coeficientes de las componentes coseno y seno asociadas al período $P_j$ , respectivamente.

Cada componente sinusoidal permite representar una periodicidad distinta dentro de la serie temporal.

### 2.3.3. Formulación Final del Modelo Temporal

Por lo tanto, el Modelo Temporal es

$$\mu(t) = \left[ L + \frac{K - L}{\left(1 + Ae^{-(\theta_0 + \theta_1 t + \theta_2 t^2)}\right)^{1/\nu}} \right] \cdot \exp \left[ \begin{array}{c} a_1 \cos\left(\frac{2\pi t}{P_1}\right) + b_1 \sin\left(\frac{2\pi t}{P_1}\right) \\ + a_2 \cos\left(\frac{2\pi t}{P_2}\right) + b_2 \sin\left(\frac{2\pi t}{P_2}\right) \\ \cdots \\ + a_n \cos\left(\frac{2\pi t}{P_n}\right) + b_n \sin\left(\frac{2\pi t}{P_n}\right) \end{array} \right].$$

# 3. Problema de Optimización con Regularización Ridge

El objetivo del algoritmo consiste en estimar los parámetros del modelo temporal y de la distribución de Poisson Generalizada mediante el método de máxima verosimilitud, desarrollado sistemáticamente por Fisher (Fisher, 1922).

Maximizar la verosimilitud de la muestra es equivalente a minimizar la log-verosimilitud negativa. Por lo tanto, se define la función de pérdida

$$\mathcal{J}_{\mathrm{NLL}}(\boldsymbol{\theta}, \rho) = -\log\left(\mathcal{L}(\boldsymbol{\theta}, \rho \mid \boldsymbol{y})\right)$$

Utilizando la parametrización de la distribución de Poisson Generalizada, la función de log-verosimilitud negativa queda dada por

$$\mathcal{J}_{\mathrm{NLL}}(\boldsymbol{\theta}, \rho) = \sum_{t=1}^{T} \Bigg[ \mu(t;\boldsymbol{\theta})(1-\rho) + \rho y_t - \log\left(\mu(t;\boldsymbol{\theta})(1-\rho)\right) - (y_t - 1)\log\left(\mu(t;\boldsymbol{\theta})(1-\rho) + \rho y_t\right) + \log(y_t!) \Bigg]$$

Para reducir el riesgo de sobreajuste se incorpora una regularización Ridge, que corresponde a una penalización cuadrática sobre los parámetros (Hoerl and Kennard, 1970).

La penalización Ridge se define como

$$\mathcal{J}_{\mathrm{Ridge}}(\boldsymbol{\theta}) = \lambda_{\mathrm{R}} \left( \sum_{k=1}^{p} \theta_k^2 \right)$$

donde $\lambda_{\mathrm{R}} \geq 0$ representa el parámetro que controla la intensidad de la regularización.

Por lo tanto, la función objetivo total del algoritmo queda definida como

$$\mathcal{J}(\boldsymbol{\theta}, \rho) = \mathcal{J}_{\mathrm{NLL}}(\boldsymbol{\theta}, \rho) + \mathcal{J}_{\mathrm{Ridge}}(\boldsymbol{\theta})$$

El problema de optimización puede expresarse entonces como

$$(\boldsymbol{\theta}^*, \rho^*) = \arg\min_{\boldsymbol{\theta}, \rho} \mathcal{J}(\boldsymbol{\theta}, \rho)$$

# Bibliografía

## Referencias


Taylor, B. (1715). *Methodus Incrementorum Directa et Inversa*. William Innys, London, England.

Fourier, J. B. J. (1822). *Théorie analytique de la chaleur*. Firmin Didot, Paris, France.

Fisher, R. A. (1922). On the Mathematical Foundations of Theoretical Statistics. *Philosophical Transactions of the Royal Society of London. Series A*, 222, 309-368. https://doi.org/10.1098/rsta.1922.0009 doi:10.1098/rsta.1922.0009.

Richards, F. J. (1959). A Flexible Growth Function for Empirical Use. *Journal of Experimental Botany*, 10(2), 290-301. doi:10.1093/jxb/10.2.290.

Winters, P. R. (1960). Forecasting Sales by Exponentially Weighted Moving Averages. *Management Science*, 6(3), 324-342. doi:10.1287/mnsc.6.3.324.

Hoerl, A. E. y Kennard, R. W. (1970). Ridge Regression: Biased Estimation for Nonorthogonal Problems. *Technometrics*, 12(1), 55-67. doi:10.1080/00401706.1970.10488634.

Consul, P. C. y Jain, G. C. (1973). A Generalization of the Poisson Distribution. *Technometrics*, 15(4), 791-799. doi:10.1080/00401706.1973.10489112.

Taylor, S. J. y Letham, B. (2018). Forecasting at Scale. *The American Statistician*, 72(1), 37-45. doi:10.1080/00031305.2017.1380080.